1. 개요

배경 및 동기:

- **프로젝트 목적:**
  밸브 고장 진단을 위한 정상 상태 밸브의 유량 예측 모델 개발. 정상 밸브의 유량을 예측함으로써 고장 상태와의 차이를 분석하여 이상 징후를 조기에 탐지할 수 있도록 함.
- **데이터의 특성:**
  실제 사용중인 밸브에서 수집한 데이터로, 개도율, 입력 압력 3개, 출력 압력 3개가 포함됨.
- **데이터 처리:**
  데이터의 소수점 자릿수가 한 자리에서 두 자리로 매우 제한적이어서 정수처럼 다루었으며, 정규화는 진행하지 않고 이상치만 처리함.

---

2. 데이터 및 전처리 (Data and Preprocessing)

데이터 설명:

- **입력 변수:**
  - 밸브 개도율 (시계열 데이터를 따름)
  - 압력 데이터: 입력 압력 3개, 출력 압력 3개
- **타겟 변수:**
  - 실제 측정된 유량 (정수로 취급)
- **데이터 특성:**
  데이터의 정밀도가 소수점 한두 자리로 제한되어 있어 추가적인 정규화 없이 정수 값처럼 활용.

전처리 방법:

- **이상치 처리:**
  데이터 분포를 분석하고 명백한 이상치(outlier)를 제거하거나 보완하는 작업을 진행함.
- **정규화 미진행 사유:**
  데이터가 이미 정수 값으로 취급될 수 있을 정도의 신뢰성을 보였기 때문에 정규화 없이 원본 값 그대로 사용.

---

3. 모델 설계 및 방법론 (Modeling & Methodology)

모델 선택 배경:

- **시계열 데이터 특성:**
  밸브 개도율의 변화에 따라 동적인 유량 변화가 발생하기 때문에 시계열 데이터를 처리에 강점을 지닌 LSTM(Long Short-Term Memory) 모델을 선택.

- **예측 성능 향상:**
  기본적인 LSTM 모델만 사용할 때 MAPE(Mean Absolute Percentage Error)값이 10 정도였으나, encoder 구조를 통해 데이터를 압축한 후 예측 모델로 전환하여 MAPE를 0.188까지 낮출 수 있었음.

모델 아키텍처 및 구성:
아래는 모델 아키텍처의 예시로, 데이터를 인코딩하여 차원을 압축한 후 예측 모델로 전환하는 구조입니다.

```
model = Sequential()
# Autoencoder 의 인코딩 부분
model.add(LSTM(16, input_shape=(seq_length, n_features), return_sequences=False))
model.add(RepeatVector(seq_length))


# LSTM 예측 모델 부분
model.add(LSTM(64, return_sequences=False))
model.add(Dense(64, activation='relu'))
model.add(Dense(1, activation='linear'))
```

- **구성 설명:**
  - **인코딩 단계:**
    첫 번째 LSTM 층(16 유닛)을 통해 입력 시계열 데이터의 주요 패턴을 추출하고, RepeatVector를 통해 시계열 구조를 유지하면서 데이터를 압축합니다.
  - **예측 모델:**
    인코딩된 데이터를 다시 LSTM (64 유닛) 층과 Dense 층으로 처리하여 최종적으로 유량을 예측.
- **손실 함수 및 최적화:**
  - Huber 손실 함수(Delta 값 설정)를 사용하여 이상치에 민감하지 않은 안정적인 학습을 도모.
  - 최적화 기법(예: Adam, RMSProp 등)을 적용하여 모델 파라미터를 최적화함.

```
model.compile(optimizer=optimizer,
                      loss=tf.keras.losses.Huber(delta=delta_value),
                      metrics=['mae', 'mape'])
```

모델 개선 효과:

- 기본 LSTM 모델 대비 인코더를 추가한 구조를 사용함으로써 MAPE가 약 10에서 0.188까지 개선되는 성능 향상을 확인.

---

4. 결과 및 분석 (Results & Analysis)

모델 평가:

- **평가지표:**
  - Loss: 4.0376096876570955e-05
  - Mae:0.003941343165934086
  - Mape: 0.18350057303905487
- **결과 시각화:**

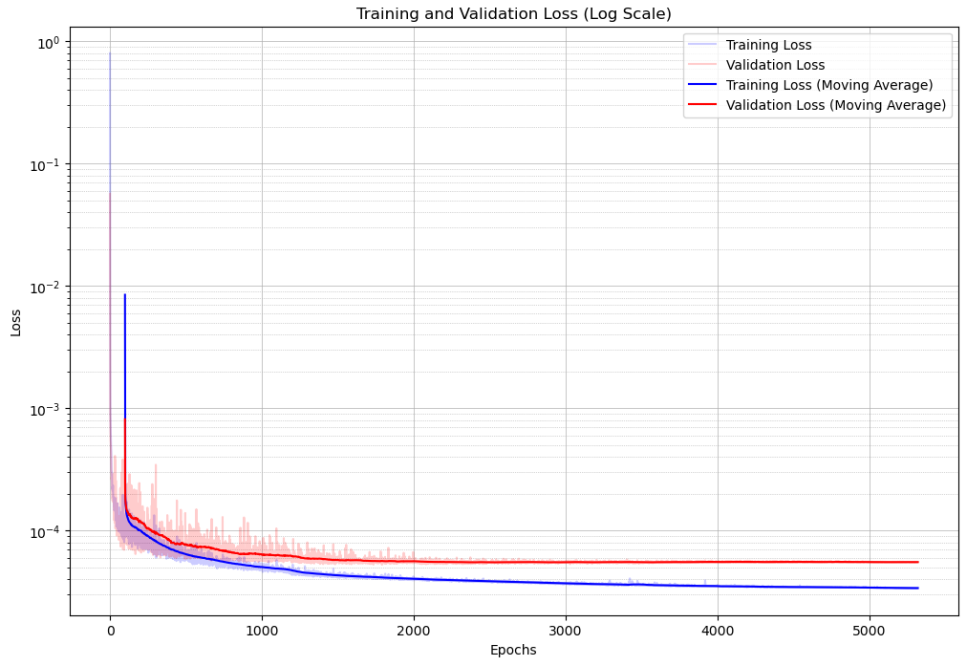

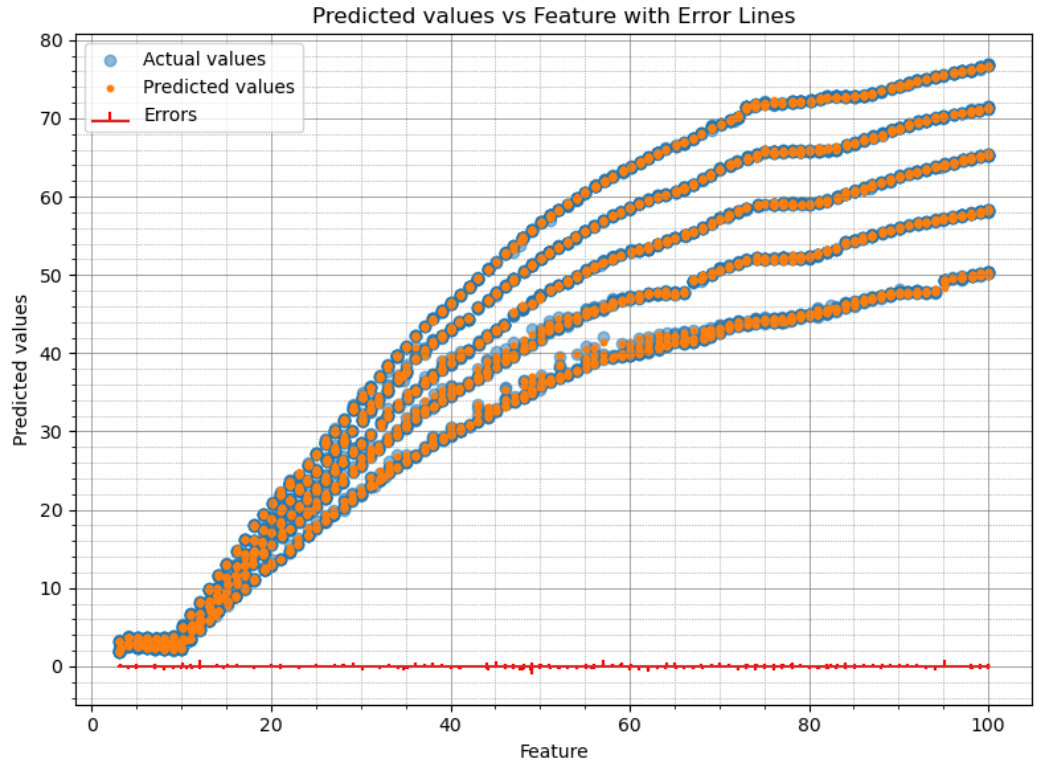

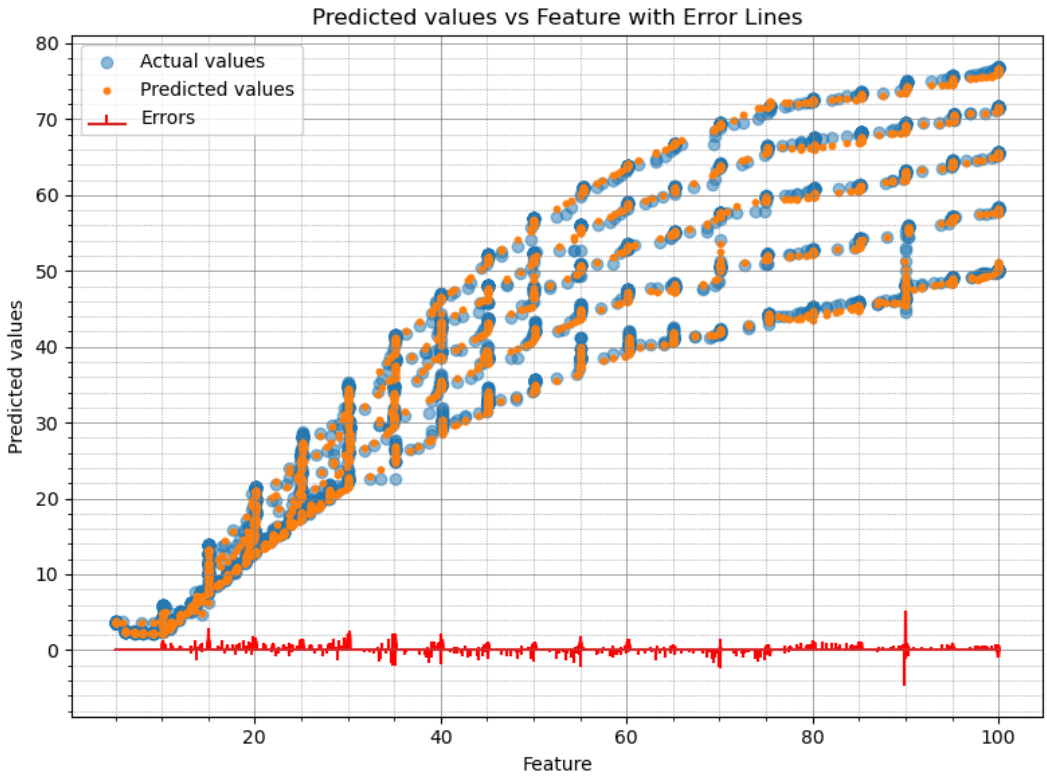
Predicted values vs Feature with Error Lines
Actual values
Predicted values
Errors
Predicted values
Feature
80
70
60
50
40
30
20
10
0
20
40
60
80
100

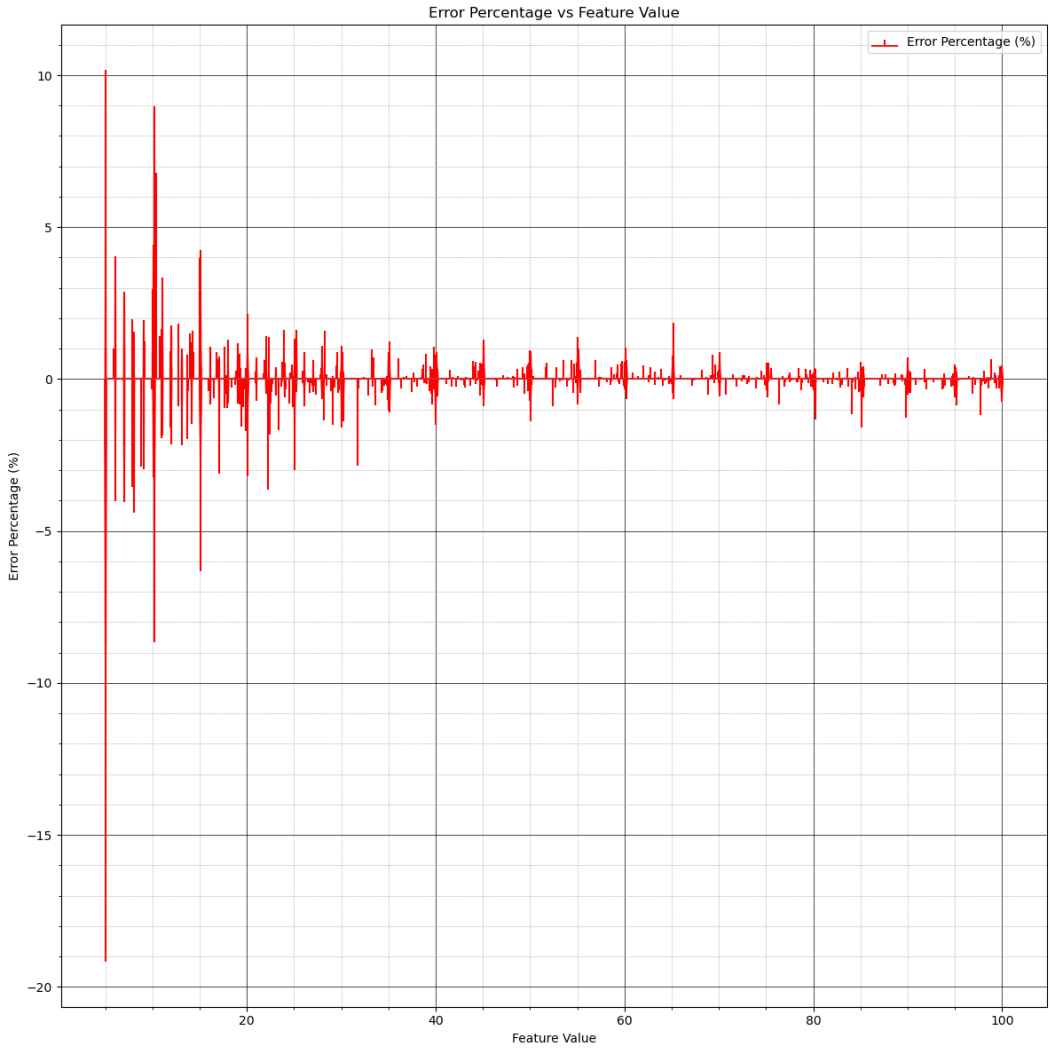
Error Percentage vs Feature Value
Error Percentage (%)
Error Percentage (%)
Feature Value
10
5
0
−5
−10
−15
−20
20
40
60
80
100